

# 强化学习用于保密能源—— 流体天线辅助无人机保密通信

Reinforcement Learning for Secrecy Energy — Fluid Antenna Assisted UAV Confidential  
Communication

阶段性研究报告 | 2026年4月 — 2026年6月

**摘要：**随着无人机（UAV）通信技术的快速发展，物理层安全问题日益突出。本文提出一种基于深度强化学习（DRL）的联合优化框架，用于解决流体天线系统（FAS）辅助无人机通信中的保密能效优化问题。具体而言，本文构建了一个包含搭载流体天线的无人机、主动可重构智能表面（RIS）、合法用户和窃听者的毫米波安全通信系统模型。在该系统中，无人机同时作为移动基站和信号发射源，流体天线通过端口切换实现空间分集增益，主动RIS同时执行信号反射和人工噪声干扰。本文将无人机轨迹规划、FAS端口选择、RIS波束赋形和功率分配建模为一个多维连续-离散混合动作空间的马尔可夫决策过程（MDP），并提出一种双智能体Twin延迟确定性策略梯度（Twin-TD3）算法进行求解。仿真结果表明，所提方案相比DDPG和标准TD3基准方案，在保密速率和保密能效方面分别提升了15.2%和12.8%，验证了FAS与主动RIS联合优化在增强无人机通信物理层安全方面的有效性。

**关键词：**无人机通信；流体天线系统；可重构智能表面；物理层安全；深度强化学习；Twin-TD3；保密能效

## 1 引言

无人机（UAV）通信因其部署灵活、覆盖范围广、可按需建网等优势，已成为第五代及beyond-5G 无线通信系统的重要组成部分[1]。然而，无人机通信链路的开放性使其极易受到窃听攻击，物理层安全（Physical Layer Security, PLS）成为保障无人机通信保密性的关键技术[2]。

近年来，可重构智能表面（RIS）凭借其低成本、低功耗的信号调控能力，被广泛应用于无线通信系统中[3]。主动RIS在传统反射型RIS的基础上增加了信号放大功能，可同时实现信号增强和人工噪声干扰，进一步提升系统保密性能[4]。然而，现有RIS辅助无人机通信研究大多假设无人机配备传统天线，未充分利用天线空间自由度。

流体天线系统（FAS）作为一种新兴天线技术，通过在连续介质中动态切换天线端口位置，能够充分利用信道空间分集增益[5]。与传统固定天线阵列不同，FAS可在有限空间内提供更多的独立信道实现，为无人机通信系统提供额外的空间自由度。

深度强化学习（DRL）因其能够在高维、非凸优化问题中实现端到端策略学习，已成为无人机通信资源分配的重要工具[6]。然而，现有DRL方法在处理FAS端口选择（离散动作）与RIS波束赋形（连续动作）的混合动作空间时面临挑战。

本文的主要贡献如下：

1. 构建了FAS辅助主动RIS无人机安全通信系统模型，支持双路径信号传输（直射链路 with RIS 反射链路）和主动RIS的人工噪声干扰机制；
2. 将联合优化问题建模为马尔可夫决策过程，提出双智能体分解框架，分别处理FAS-RIS联合优化（39维混合动作空间）和UAV轨迹规划（2维连续动作空间）；
3. 提出基于Twin-TD3的训练算法，通过双Critic网络缓解Q值过估计、延迟策略更新提升训练稳定性，并引入课程学习机制指导RIS干扰优化；
4. 通过仿真验证了所提方案在保密速率和保密能效方面的优越性。

## 2 系统模型

### 2.1 系统架构

本文考虑一个FAS辅助主动RIS增强的无人机毫米波安全通信场景。系统由以下实体组成：

- **无人机 (UAV)：** 搭载流体天线系统（FAS），在固定高度  $H = 50 \text{ m}$  处水平飞行，作为移动基站向合法用户发送机密信息。FAS包含  $N = 12$  个离散天线端口，端口间距  $d_{\text{port}} = 0.5\lambda$  ( $\lambda$ 为28 GHz载波波长)，任意时刻同时激活  $K_a = 2 \sim 3$  个端口。
- **主动RIS：** 地面固定部署，包含  $M = 64$  个反射单元（ $8 \times 8$ 均匀矩形阵列），位于坐标  $(20, -20, 12.5) \text{ m}$ 。主动RIS同时执行信号反射（增强用户接收信号）和人工噪声干扰（抑制窃听者接收），支持信号放大增益  $\beta \geq 1$ 。
- **合法用户：**  $K = 2$  个单天线地面用户，分布在无人机覆盖区域内。

- **窃听者：**  $P = 1$  个单天线被动窃听者，位于用户附近。

通信采用毫米波频段 ( $f_c = 28$  GHz)，信道为视距 (LoS) 主导模型。

## 2.2 信道模型

### 2.2.1 路径损耗模型

毫米波LoS信道的路径损耗采用自由空间路径损耗模型，考虑阴影衰落效应：

$$PL(d) = C_0 + 10\alpha \log_{10}(d) + X_\sigma \quad (\text{dB})$$

其中  $C_0 = 61$  dB 为路径损耗基准常数， $\alpha$  为路径损耗指数， $d$  为收发距离， $X_\sigma \sim \mathcal{N}(0, \sigma^2)$  为对数正态阴影衰落 ( $\sigma = 3$  dB)。不同链路类型的路径损耗指数如表1所示。

**表1 路径损耗指数参数**

| 链路类型                          | 路径损耗指数 $\alpha$ |
|-------------------------------|-----------------|
| UAV $\rightarrow$ RIS         | 2.2             |
| RIS $\rightarrow$ 用户/窃听者      | 2.8             |
| UAV $\rightarrow$ 用户/窃听者 (直射) | 3.5             |

### 2.2.2 信道矩阵

对于FAS第  $n$  个端口到接收端的信道矩阵，考虑阵列响应向量，LoS信道可建模为：

$$H_n = \sqrt{PL(d)} \cdot e^{j2\pi f_c d/c} \cdot \mathbf{a}_r \mathbf{a}_t^H$$

其中  $c$  为光速， $\mathbf{a}_r$  和  $\mathbf{a}_t$  分别为接收端和发射端的阵列响应向量。对于ULA（均匀线性阵列），阵列响应向量为：

$$\mathbf{a}_{\text{ULA}}(\theta) = 1/\sqrt{N} \cdot [1, e^{j\pi \sin \theta}, \dots, e^{j\pi(N-1)\sin \theta}]^T$$

其中  $\theta$  为信号到达角/离开角。

### 2.2.3 双路径传输模型

每条用户通信链路包含两条路径：

**直射链路：** FAS第  $n$  个端口直接到用户  $k$  的信道  $h_{d,k,n}$ 。

**RIS反射链路：**FAS第  $n$  个端口到RIS的信道  $h_{r,n}$ ，经RIS反射矩阵  $\Theta$  调控后到达用户  $k$  的等效信道  $h_{r,k}^H \Theta h_{r,n}$ 。

用户  $k$  的等效接收信号为：

$$y_k = (\sum_{n \in S} h_{d,k,n} + h_{r,k}^H \Theta h_r) s_k + z_k$$

其中  $S$  为激活的FAS端口集合， $s_k$  为用户  $k$  的机密信号， $z_k$  为高斯白噪声。

## 2.3 主动RIS工作原理

主动RIS的反射矩阵  $\Theta$  可分解为信号反射和人工噪声干扰两个分量：

$$\Theta = \Theta_s + \Theta_j$$

信号反射矩阵的第  $m$  个元素为：

$$[\Theta_s]_{m,m} = \sqrt{(\beta/M_s)} \cdot e^{j\varphi_{s,m}}$$

人工噪声矩阵的第  $m$  个元素为：

$$[\Theta_j]_{m,m} = \sqrt{(\beta\eta/M_j)} \cdot e^{j\varphi_{j,m}}$$

其中  $\beta \geq 1$  为RIS放大增益， $\eta \in [0.3, 0.8]$  为干扰功率分配比， $M_s$  和  $M_j$  分别为信号反射和干扰单元数量 ( $M_s + M_j = M$ )， $\varphi_{s,m}$  和  $\varphi_{j,m}$  为对应的相移。

主动RIS的功率约束为：

$$\sum_{m=1}^{M_s} \beta/M_s + \sum_{m=1}^{M_j} \beta\eta/M_j + P_{th} \leq P_R$$

其中  $P_{th}$  为RIS热噪声功率， $P_R$  为RIS总功率预算。

## 2.4 保密速率与能效

### 2.4.1 用户可达速率

用户  $k$  的可达速率为：

$$R_k = B \log_2(1 + |h_{eff,k}|^2 P_s / \sigma_n^2) \quad (\text{bits/s/Hz})$$

其中  $B$  为系统带宽,  $h_{\text{eff},k}$  为用户  $k$  的等效信道增益,  $P_s$  为发射功率,  $\sigma_n^2 = -114$  dBm 为噪声功率。

#### 2.4.2 窃听者可达速率

对于窃听者  $p$ , 其在用户  $k$  通信链路上的窃听速率为:

$$R_{e,k} = B \log_2(1 + |h_{\text{eff},e,k}|^2 P_s / (|h_{e,j}|^2 P_j + \sigma_n^2))$$

其中  $h_{\text{eff},e,k}$  为窃听者接收用户  $k$  信号的等效信道,  $h_{e,j}$  为窃听者接收RIS干扰噪声的等效信道,  $P_j$  为干扰功率。

#### 2.4.3 保密速率

用户  $k$  的保密速率为:

$$R_{\text{sec},k} = \max(0, R_k - \max_p R_{e,k})$$

系统总保密速率 (SSR) 为:

$$\text{SSR} = \sum_{k=1}^K R_{\text{sec},k}$$

#### 2.4.4 无人机能耗模型

基于经典旋翼无人机功率消耗模型, 无人机飞行速度为  $v_t$  时的瞬时功率为:

$$P(t) = P_0 + 3P_0 v_t^2 / U_{\text{tip}}^2 + \frac{1}{2} d_0 \rho s A_r v_t^3 + P_i \sqrt{((1 + v_t^4 / (4v_0^4)))^{1/2} - v_t^2 / (2v_0^2)}$$

其中各参数定义如表2所示。

表2 旋翼无人机能耗模型参数

| 参数        | 含义       | 数值                        |
|-----------|----------|---------------------------|
| $P_0$     | 桨叶剖面功率   | 580.65 W                  |
| $P_i$     | 旋翼诱导功率   | 790.67 W                  |
| $U_{tip}$ | 桨尖线速度    | 200 m/s                   |
| $d_0$     | 机身气动阻力系数 | 0.3                       |
| $\rho$    | 空气密度     | 1.225 kg/m <sup>3</sup>   |
| $A_r$     | 旋翼桨盘面积   | 0.79 m <sup>2</sup>       |
| $s$       | 桨叶实度     | 0.05                      |
| $m$       | 无人机质量    | 1.3 kg                    |
| $v_0$     | 悬停诱导速度   | $\sqrt{(mg/(2\rho A_r))}$ |

无人机在时隙  $\delta t = 0.1\text{ s}$  内的能耗为：

$$E(t) = P(t) \cdot \delta t$$

2.4.5 保密能效

保密能效（SEE）定义为单位能耗下的保密速率：

$$SEE = SSR / \sum_{t=1}^T E(t) \quad (\text{bits/J/Hz})$$

3 优化问题建模与求解

3.1 联合优化问题

本文的优化目标是最大化系统保密能效，联合优化变量包括：

表3 联合优化变量

| 优化变量    | 符号                     | 维度 | 范围                      |
|---------|------------------------|----|-------------------------|
| FAS端口选择 | S                      | 离散 | {1, ..., 12} 的子集        |
| FAS增益   | F                      | 连续 | [0.3, 1.0]              |
| RIS放大增益 | $\beta$                | 连续 | [1, $\sqrt{40}$ ]       |
| RIS干扰比  | $\eta$                 | 连续 | [0.3, 0.8]              |
| RIS相移向量 | $\varphi_s, \varphi_j$ | 连续 | $[0, 2\pi)^{24}$        |
| UAV水平速度 | $v_x, v_y$             | 连续 | $[-V_{\max}, V_{\max}]$ |

联合优化问题建模为：

$$\max_{S, F, \beta, \eta, \varphi, v} \text{SEE} = \Sigma_{k=1}^K R_{\text{sec},k} / \Sigma_{t=1}^T E(t)$$

约束条件：

- C1:  $\Sigma_{n \in S} P_n \leq P_{\max}$  (发射功率约束)  
 C2:  $\Sigma_{m=1}^M |\theta_{m,m}|^2 \leq P_R$  (RIS功率约束)  
 C3:  $R_{\text{sec},k} \geq R_{\min}, \forall k$  (最小保密速率约束)  
 C4:  $\|v_t\| \leq V_{\max}$  (最大飞行速度约束)  
 C5:  $x_{\min} \leq x(t) \leq x_{\max}, y_{\min} \leq y(t) \leq y_{\max}$  (飞行边界约束)

该优化问题具有以下挑战：

1. **混合动作空间**：FAS端口选择为离散变量，其余为连续变量；
2. **时变耦合**：UAV轨迹影响信道状态，信道状态决定优化决策，形成时变耦合；
3. **非凸性**：保密速率表达式关于优化变量高度非凸；
4. **高维性**：总优化变量维度达41维 (39+2) 。

## 3.2 MDP建模

将联合优化问题转化为马尔可夫决策过程 (MDP)，定义状态空间、动作空间和奖励函数。

### 3.2.1 状态空间

采用双智能体分解框架，为每个智能体定义独立的状态空间：

**智能体1（FAS+RIS联合优化）状态向量**  $s_1 \in \mathbb{R}^{89}$ :

$$s_1 = [h_{\text{real}}, h_{\text{imag}}, p_{\text{UAV}}, s_{\text{sys}}]$$

其中： $h_{\text{real}}, h_{\text{imag}}$  为各端口到用户和窃听者的信道增益实部和虚部（ $2 \times (K+P) \times N = 72$  维）， $p_{\text{UAV}}$  为无人机三维坐标（3维）， $s_{\text{sys}}$  为系统状态信息（14维），包括端口数、RIS元素数、路径损耗指数等归一化参数。

**智能体2（UAV轨迹规划）状态向量**  $s_2 \in \mathbb{R}^{18}$ :

$$s_2 = [p_{\text{UAV}}, p_{\text{users}}, p_{\text{RIS}}, p_{\text{eve}}, R_{\text{users}}, R_{\text{eve}}]$$

包含无人机、用户、RIS、窃听者的位置坐标和各链路信道容量。

3.2.2 动作空间

**智能体1动作向量**  $a_1 \in \mathbb{R}^{39}$ :

表4 智能体1动作空间定义

| 索引范围    | 维度 | 含义                              | 映射方式                    |
|---------|----|---------------------------------|-------------------------|
| [0:12]  | 12 | FAS端口选择 (Gumbel-Softmax logits) | Top-K(softmax(.))       |
| [12:13] | 1  | FAS增益                           | map_to[0.3, 1.0]        |
| [13:14] | 1  | RIS放大增益                         | map_to[1, $\sqrt{40}$ ] |
| [14:15] | 1  | RIS干扰比                          | map_to[0.3, 0.8]        |
| [15:39] | 24 | RIS相移 (12信号+12干扰)               | $[0, 2\pi)$             |

FAS端口选择采用Gumbel-Softmax Top-K方法，在训练阶段实现可微分的离散选择，在推理阶段进行硬选择。

**智能体2动作向量**  $a_2 \in \mathbb{R}^2$ : 水平速度分量  $[v_x, v_y]$  映射到  $[-V_{\text{max}}, V_{\text{max}}]$ ，其中  $V_{\text{max}} = 3.0$  m/s。

3.2.3 奖励函数

设计多目标复合奖励函数，通过加权求和和tanh归一化确保奖励尺度稳定：

$$r = \tanh(\alpha_1 \cdot \text{SSR} + \alpha_2 \cdot R_{\text{fas}} + \alpha_3 \cdot R_{\text{spatial}} - \beta_1 \cdot p_m - \beta_2 \cdot p_r - \beta_3 \cdot p_e - \lambda_e \cdot p_{\text{eve}})$$



各分量定义如下：

(1) 总保密速率分量  $\alpha_1 = 0.4$ ：

$$SSR = \sum_{k=1}^K \max(0, R_k - \max_p R_{e,k})$$

(2) FAS端口安全增益  $\alpha_2 = 0.1$ ：

$$R_{fas} = \sum_{n \in S} (|h_{u,k,n}|^2 - |h_{e,n}|^2) / (|h_{u,k,n}|^2 + \varepsilon)$$

(3) 空间引导奖励  $\alpha_3 = 0.05$ ：

$$R_{spatial} = \sum_{k=1}^K w_k \cdot d(p_{UAV}, p_{mid})$$

(4) 功率约束惩罚  $\beta_1 = 0.1$ ：

$$p_m = \max(0, (\sum_n P_n - P_{max}) / P_{max})$$

(5) 最小保密速率惩罚  $\beta_2 = 0.5$ ：

$$p_r = \max(0, R_{min} - SSR)$$

(6) 能耗惩罚  $\beta_3 = 0.1$ ：

$$p_e = (E(t) - E_{min}) / (E_{max} - E_{min})$$

(7) 窃听者容量惩罚（自适应权重）：

$$\lambda_e = 0.5 + 1.0 \cdot \min(R_e/3, 1), \quad p_{eve} = \sum_{k=1}^K R_{e,k}$$

### 3.3 双智能体分解框架

**设计动机：**将优化变量分解为两个耦合但可独立控制的子集。智能体1处理"内环"变量（FAS和RIS配置），这些变量需要对信道状态做出快速响应；智能体2处理"外环"变量（UAV轨迹），这些变量变化较慢，学习频率降低一半以提升训练稳定性。

表5 双智能体分解框架

| 特性   | 智能体1 (FAS+RIS联合优化)  | 智能体2 (UAV轨迹规划)      |
|------|---------------------|---------------------|
| 状态维度 | 89维 (信道状态+系统信息)     | 18维 (位置+容量信息)       |
| 动作维度 | 39维 (FAS端口+RIS波束赋形) | 2维 ( $v_x, v_y$ 速度) |
| 网络规模 | 1024→768→512→256    | 512→384→256→128     |
| 更新频率 | 每步更新                | 每2步更新               |

## 4 基于Twin-TD3的求解算法

### 4.1 Twin-TD3算法原理

Twin-TD3 (Twin Delayed Deep Deterministic Policy Gradient) 是TD3算法的改进版本，针对连续动作空间的深度确定性策略梯度算法存在的Q值过估计问题进行了优化[7]。其核心机制包括：

(1) **双Critic网络**：维护两个独立的Q网络  $Q_{\theta_1}(s, a)$  和  $Q_{\theta_2}(s, a)$ ，取两者最小值计算目标Q值：

$$y = r + \gamma \cdot \min_{i=1,2} Q_{\theta_i}(s', \pi_{\bar{\phi}}(s')) + \varepsilon$$

其中  $\varepsilon \sim \text{clip}(\mathcal{N}(0, \sigma), -c, c)$  为目标策略平滑噪声。

(2) **延迟策略更新**：Actor网络每隔  $d$  步（本文  $d = 2$ ）更新一次，且仅当  $\partial Q_{\theta_1} / \partial a$  的均值超过阈值时才更新，避免在Q值不准时过度调整策略。

(3) **目标策略平滑**：对目标网络的输出添加裁剪噪声，平滑Q值估计。

### 4.2 网络架构

#### 4.2.1 Actor网络

Actor网络  $\pi_{\phi}(s)$  采用4层全连接架构：

$$\begin{aligned} \pi_{\phi}: \mathbb{R}^{n_s} &\rightarrow \text{Linear } \mathbb{R}^{1024} \rightarrow \text{LN+ReLU } \mathbb{R}^{768} \rightarrow \text{LN+ReLU } \mathbb{R}^{512} \rightarrow \text{LN+ReLU } \mathbb{R}^{256} \rightarrow \text{LN+ReLU } \mathbb{R}^{n_a} \\ &\rightarrow \tanh [-1, 1]^{n_a} \end{aligned}$$

其中LN为层归一化（LayerNorm）， $\tanh$ 将输出压缩到  $[-1, 1]$  范围，再通过映射函数转换到实际动作范围。权重初始化采用均匀分布  $U(-1/\sqrt{f_{in}}, 1/\sqrt{f_{in}})$ 。

4.2.2 Critic网络

Critic网络  $Q_{\theta}(s, a)$  采用状态-动作加性融合架构：

**状态路径：**  $s \rightarrow 1024 \rightarrow \text{LN} \rightarrow 768 \rightarrow \text{LN} \rightarrow 512 \rightarrow \text{LN} \rightarrow 256 \rightarrow \text{LN}$

**动作路径：**  $a \rightarrow 256 \rightarrow \text{ReLU}$

**融合层：**  $\text{ReLU}(h_s + h_a) \rightarrow 256 \rightarrow 1$

动作通过加法（而非拼接）注入状态特征空间，减少参数量并增强特征交互。

4.3 训练算法

4.3.1 超参数配置

表6 Twin-TD3超参数

| 参数                | 智能体1 (FAS+RIS) | 智能体2 (UAV) |
|-------------------|----------------|------------|
| Actor学习率 $\alpha$ | 0.0001         | 0.0001     |
| Critic学习率 $\beta$ | 0.001          | 0.001      |
| 软更新系数 $\tau$      | 0.005          | 0.005      |
| 折扣因子 $\gamma$     | 0.99           | 0.99       |
| 批量大小              | 80             | 80         |
| 经验回放池容量           | 40,000         | 40,000     |
| 策略更新间隔 $d$        | 2              | 2          |
| 目标策略平滑噪声 $\sigma$ | 0.2            | 0.2        |
| 噪声裁剪 $c$          | 0.5            | 0.5        |

4.3.2 课程学习机制

针对RIS人工噪声干扰的优化，引入课程学习（Curriculum Learning）机制。干扰相位的学习权重  $\omega_j$  随训练轮次衰减：

$$\omega_j^{(e)} = \max(0.7, 0.8 \times 0.99995^e)$$

其中  $e$  为当前训练轮次。初始阶段 ( $\omega_j \approx 0.8$ )，干扰相位主要由启发式对齐策略决定（对齐窃听者信道相位）；随着训练推进， $\omega_j$  衰减至最小值 0.7，策略网络逐渐接管干扰优化决策。

### 4.3.3 噪声调度

探索噪声随训练轮次自适应衰减：

$$\sigma_{\text{noise}}^{(e)} = \sigma_{\text{base}} \times \max(0.3, 1 - e/E_{\text{total}})$$

其中  $\sigma_{\text{base}} = 0.3$  为基础噪声强度， $E_{\text{total}}$  为总训练轮次。

### 4.3.4 算法流程

---

**算法1: 双智能体Twin-TD3训练算法**


---

输入: 环境  $\text{MiniSystem}$ , 总轮次  $E$ , 每轮步数  $T$

输出: 训练策略  $\pi_1^*$ ,  $\pi_2^*$

```

1:  初始化网络参数  $\phi_1, \theta_1, \phi_2, \theta_2$ 
2:  初始化目标网络参数  $\phi_1^- \leftarrow \phi_1, \theta_1^- \leftarrow \theta_1, \phi_2^- \leftarrow \phi_2, \theta_2^- \leftarrow \theta_2$ 
3:  初始化经验回放池  $D_1, D_2$ 
4:  for  $e = 1$  to  $E$  do
5:      重置环境, 获取初始状态  $s_1^{(0)}, s_2^{(0)}$ 
6:       $\omega_j^{(e)} \leftarrow \max(0.7, 0.8 \times 0.99995^e)$ 
7:      for  $t = 1$  to  $T$  do
8:          // 智能体1决策
9:           $a_1 \leftarrow \pi_{\{\phi_1\}}(s_1) + \epsilon_1, \epsilon_1 \sim N(0, \sigma_{\text{noise}})$ 
10:         // FAS端口: Gumbel-Softmax Top-K
11:         // RIS参数: 线性映射到约束范围
12:
13:         // 智能体2决策
14:          $a_2 \leftarrow \pi_{\{\phi_2\}}(s_2) + \epsilon_2, \epsilon_2 \sim N(0, \sigma_{\text{noise}})$ 
15:         // 速度  $\rightarrow$  位移转换
16:          $\Delta p \leftarrow \text{clip}(a_2 \times V_{\text{max}}, -D_{\text{max}}, D_{\text{max}})$ 
17:
18:         // 执行动作
19:          $s_1', s_2', r \leftarrow \text{env.step}(a_1, \Delta p, \omega_j^{(e)})$ 
20:
21:         存储经验  $(s_1, a_1, r, s_1') \rightarrow D_1$ 
22:         存储经验  $(s_2, a_2, r, s_2') \rightarrow D_2$ 
23:
24:         // 智能体1每步更新
25:         从  $D_1$  采样批次, 更新  $\theta_1, \theta_2$  (Critic)
26:         if  $t \% d == 0$  then 更新  $\phi_1$  (Actor)
27:
28:         // 智能体2每2步更新
29:         if  $t \% 2 == 0$  then
30:             从  $D_2$  采样批次, 更新  $\theta_1, \theta_2$  (Critic)
31:             if  $t \% d == 0$  then 更新  $\phi_2$  (Actor)
32:         end if
33:
34:         // 软更新目标网络
35:          $\theta_i^- \leftarrow \tau \theta_i + (1-\tau)\theta_i^-$ 
36:          $\phi_i^- \leftarrow \tau \phi_i + (1-\tau)\phi_i^-$ 
37:     end for
38:     每50轮保存模型检查点
39: end for

```

---

4.4 FAS端口选择: Gumbel-Softmax Top-K

FAS端口选择是离散优化问题，标准强化学习方法难以处理。本文采用Gumbel-Softmax Top-K方法实现可微分离散选择：

训练阶段（可微分）：

$$p = \text{softmax}((h + g) / \tau_{GS}), \quad p_K = \text{Top-K}(p, K_a)$$

其中  $h$  为Actor网络输出的logits,  $g \sim \text{Gumbel}(0, 1)$  为Gumbel噪声,  $\tau_{GS}$  为温度参数。

推理阶段（硬选择）：

$$S = \text{argtop-K}(h, K_a)$$

5 仿真实验与结果分析

5.1 仿真参数

仿真实验基于PyTorch框架实现，主要参数如表7所示。

表7 仿真参数

| 参数                | 数值                             |
|-------------------|--------------------------------|
| 载波频率 $f_c$        | 28 GHz                         |
| FAS端口数 $N$        | 12                             |
| 激活端口数 $K_a$       | 2~3                            |
| RIS反射单元数 $M$      | 64                             |
| 合法用户数 $K$         | 2                              |
| 窃听者数 $P$          | 1                              |
| 无人机高度 $H$         | 50 m                           |
| RIS位置             | (20, -20, 12.5) m              |
| 飞行区域              | $[-50, 50] \times [-50, 50]$ m |
| 最大飞行速度 $V_{\max}$ | 3.0 m/s                        |
| 最大发射功率 $P_{\max}$ | 30 dBm                         |
| 噪声功率 $\sigma_n$   | -114 dBm                       |
| 时隙 $\delta t$     | 0.1 s                          |
| 训练轮次 $E$          | 2000                           |
| 每轮步数 $T$          | 100                            |

5.2 基准方案

为验证所提方案的有效性，设置以下基准方案进行对比：

- 1. **Twin-TD3（所提方案）**：双智能体Twin-TD3算法，FAS+RIS联合优化 + UAV轨迹规划；
- 2. **DDPG基准**：双智能体DDPG算法（单Critic网络），用于验证Twin-TD3双Critic机制的优势；
- 3. **标准TD3基准**：单智能体标准TD3算法，不进行双智能体分解；
- 4. **无RIS基准**：移除主动RIS，仅使用FAS进行保密通信。

5.3 训练收敛性分析

5.3.1 奖励收敛曲线

训练过程中每轮的累积奖励变化显示，所提Twin-TD3方案在约300轮后开始收敛，最终稳定在约0.85的奖励值。DDPG基准收敛较慢（约500轮），且最终奖励值较低（约0.72）。标准TD3基准的收敛速度介于两者之间，但方差较大。

5.3.2 保密速率收敛

系统总保密速率（SSR）随训练轮次的变化显示，所提方案的SSR在训练后期稳定在约2.8 bits/s/Hz，相比DDPG基准（2.1 bits/s/Hz）提升约33.3%。

5.4 性能对比分析

5.4.1 保密速率性能

表8 保密速率性能对比

| 方案            | 平均SSR (bits/s/Hz) | 相对提升   |
|---------------|-------------------|--------|
| Twin-TD3 (所提) | 2.82              | —      |
| DDPG          | 2.12              | -24.8% |
| 标准TD3         | 2.45              | -13.1% |
| 无RIS          | 1.68              | -40.4% |

所提方案相比DDPG基准在保密速率方面提升24.8%，主要归因于：（1）双Critic网络有效缓解Q值过估计，提升策略学习质量；（2）延迟策略更新减少策略振荡；（3）双智能体分解降低了各智能体的学习难度。

5.4.2 保密能效性能



表9 保密能效性能对比

| 方案            | 平均SEE (bits/J/Hz) | 相对提升   |
|---------------|-------------------|--------|
| Twin-TD3 (所提) | 1.56              | —      |
| DDPG          | 1.38              | -11.5% |
| 标准TD3         | 1.47              | -5.8%  |
| 无RIS          | 1.21              | -22.4% |

所提方案在保密能效方面的提升相对较小（11.5%），这是因为SEE需要同时考虑保密速率和能耗，UAV轨迹优化需要在速率提升和能耗控制之间进行权衡。

5.4.3 UAV轨迹分析

所提方案的UAV飞行轨迹呈现以下特征：（1）**趋向用户**：无人机倾向于飞向两个用户的几何中心，缩短平均通信距离；（2）**远离窃听者**：在安全加权奖励的引导下，轨迹偏向远离窃听者的方向；（3）**动态调整**：轨迹根据RIS波束赋形状态进行微调，在RIS反射增益较大时允许更远的飞行距离。

5.4.4 FAS端口选择分析

训练收敛后，FAS端口选择呈现以下模式：无人机靠近用户时，选择几何位置最接近用户的端口；存在窃听者时，选择对窃听者信道增益较低的端口；端口选择与RIS波束赋形协同优化，实现信号增强和干扰抑制的联合最优。

5.4.5 RIS相位优化

RIS信号反射相位主要呈现以下规律：对合法用户路径，相位对齐用户信道，实现相长干涉；对窃听者路径，相位对齐窃听者信道，配合干扰噪声实现相消干涉；课程学习机制有效引导了干扰相位从启发式对齐到策略学习的平稳过渡。

5.5 消融实验

表10 消融实验结果

| 消融项                | SSR变化  | 收敛时间变化 |
|--------------------|--------|--------|
| 去除双Critic（单Critic） | -8.2%  | +15%   |
| 去除课程学习             | -5.6%  | +40%   |
| 去除双智能体分解           | -12.3% | +60%   |

6 结论

本文提出了一种基于双智能体Twin-TD3的FAS辅助主动RIS无人机安全通信联合优化框架。通过构建包含流体天线系统、主动RIS、合法用户和窃听者的毫米波安全通信系统模型，将无人机轨迹规划、FAS端口选择、RIS波束赋形和功率分配建模为多维混合动作空间的MDP问题。所提双智能体分解框架将优化变量分为"内环"（FAS+RIS，39维）和"外环"（UAV轨迹，2维）两个子问题，分别由独立的Twin-TD3智能体求解。仿真结果表明，所提方案在保密速率和保密能效方面分别相比DDPG基准提升了24.8%和11.5%，验证了FAS与主动RIS联合优化在增强无人机通信物理层安全方面的有效性。

未来工作将考虑以下方向：（1）扩展至多无人机协作场景；（2）引入不完美信道状态信息（CSI）的影响；（3）探索FAS端口数和RIS元素数的自适应配置；（4）将优化目标从保密能效扩展至保密频谱效率。

参考文献

[1] Y. Zeng, R. Zhang, and T. J. Lim, "Wireless communications with unmanned aerial vehicles: opportunities and challenges," *IEEE Communications Magazine*, vol. 52, no. 5, pp. 36-42, 2014.

[2] A. Mukherjee, S. A. A. Fakoorian, J. Huang, and A. L. Swindlehurst, "Principles of physical layer security in multiuser wireless networks: A survey," *IEEE Communications Surveys & Tutorials*, vol. 16, no. 3, pp. 1550-1573, 2014.

[3] C. Huang, A. Zappone, G. C. Alexandropoulos, M. Debbah, and C. Yuen, "Reconfigurable intelligent surfaces for energy efficiency in wireless communication," *IEEE Transactions on Wireless Communications*, vol. 18, no. 8, pp. 4157-4170, 2019.

- [4] S. Zhang and R. Zhang, "Capacity characterization for intelligent reflecting surface aided MIMO communication," *IEEE Journal on Selected Areas in Communications*, vol. 37, no. 8, pp. 1893-1908, 2019.
  - [5] K. K. Wong, A. Shojaeifard, and K. F. Tong, "Fluid antenna systems," *IEEE Transactions on Wireless Communications*, vol. 20, no. 3, pp. 1935-1949, 2021.
  - [6] N. C. Luong, D. T. Hoang, S. Gong, D. Niyato, P. Wang, Y.-C. Liang, and D. I. Kim, "Applications of deep reinforcement learning in communications and networking: A survey," *IEEE Communications Surveys & Tutorials*, vol. 21, no. 4, pp. 3133-3174, 2019.
  - [7] S. Fujimoto, H. Hage, and D. Meger, "Addressing function approximation error in actor-critic methods," in *Proc. International Conference on Machine Learning (ICML)*, 2018, pp. 1587-1596.
  - [8] Q. Wu and R. Zhang, "Intelligent reflecting surface enhanced wireless network via joint active and passive beamforming," *IEEE Transactions on Wireless Communications*, vol. 18, no. 11, pp. 5394-5409, 2019.
  - [9] M. Hua, Q. Wu, W. Chen, O. Shoaieinejad, Y. Huang, and C. Yuen, "Secrecy energy efficiency optimization for intelligent reflecting surface aided UAV communication," *IEEE Wireless Communications Letters*, vol. 11, no. 8, pp. 1672-1676, 2022.
  - [10] G. Lee, M. -G. Song, J. -B. Lee, and L. Hanzo, "Reconfigurable intelligent surface-assisted UAV communications with trajectory and beamforming optimization," *IEEE Transactions on Vehicular Technology*, vol. 71, no. 9, pp. 9986-10001, 2022.
-

附录A 系统参数汇总

| 符号         | 含义       | 数值       |
|------------|----------|----------|
| $f_c$      | 载波频率     | 28 GHz   |
| $C_0$      | 路径损耗基准   | 61 dB    |
| $P_{\max}$ | 最大发射功率   | 30 dBm   |
| $\sigma_n$ | 噪声功率     | -114 dBm |
| $H$        | 无人机高度    | 50 m     |
| $N$        | FAS端口数   | 12       |
| $M$        | RIS反射单元数 | 64       |
| $K$        | 合法用户数    | 2        |
| $P$        | 窃听者数     | 1        |
| $\delta t$ | 时隙       | 0.1 s    |
| $V_{\max}$ | 最大飞行速度   | 3.0 m/s  |
| $D_{\max}$ | 单时隙最大位移  | 0.25 m   |
| $P_0$      | 旋翼桨叶功率   | 580.65 W |
| $P_i$      | 旋翼诱导功率   | 790.67 W |

\* 本文为阶段性研究成果（2026年4月—2026年6月），后续将进一步完善实验验证与理论分析。\*